人工智能文献知识图谱：课程交付报告

冻结日期：2026-10-11；提交截止：2026-10-13。V1 为正式系统，V2 为封存实验，禁止生产替换。不再采集训练数据、启动新训练或继续调参。

1. 领域与待解决的问题

选取人工智能学术文献领域。研究者需要找到与方法、任务相关的候选文献，核对作者、发表场所及原始来源，再判断是否引用。普通书目检索较难串联“作者—论文—方法—任务”的关联。本系统将 DBLP 书目与神经网络抽取的题名候选概念关联，用 Neo4j 提供可溯源检索和多跳探索。

系统用于缩小阅读范围、组织候选文献及查看证据，不自动认定论文支持某项结论，也不自动决定必引参考文献。没有可靠引用网络，不能提供真实被引次数。

2. 数据采集、清洗与图谱

原始书目来自 DBLP 官方公开 XML 快照，不将公开数据下载伪装成自行网页爬取。通过流式解析、AI 领域筛选、字段规范化、唯一键去重及引用一致性检查，形成 20,000 篇文献的结构化 CSV。数据摘要位于 `kg_datasets/dblp/processed_ai/quality_summary.json`，处理脚本保留在 `scripts`。

题名模型实际处理 19,999 篇，1 篇因超出固定长度拒绝，没有静默截断。形成 44,904 个实体提及、21,497 条候选断言；这些数量不是正确事实数量。V1 第 58 版包含 194,597 个节点、263,059 条关系。

实体层包括 Publication、Person、Venue、Concept、Mention、Assertion。书目关系包括 AUTHORED、PUBLISHED_IN；MENTIONS 和 DENOTES 将原文提及映射到概念；SUPPORTED_BY、HAS_HEAD、HAS_TAIL 保留候选关系及证据。USED_FOR、EVALUATED_ON 保存在 Assertion 的谓词属性中，未直接当作已认证科研事实连边。

作者采用 DBLP 主页身份辅助消歧，66,093 个作者身份匹配，9,062 个未决署名独立隔离。概念只采用 38 组受控别名，18 个模型版本概念保留。不能宣称作者完全消歧或概念全面归一。

2026-10-11 再次调用现有图谱导入器：图谱已存在，跳过重复导入，核对各类节点及关系数量一致，未重置数据库。实际收据：`neo4j_import_verification.json`。此项证明现有库与提交图谱包一致，不冒充已执行空库迁移验收。

3. 实体与关系抽取流程

采用 Pipeline：SciBERT + BIO 分类头识别 METHOD / TASK / DATASET，再使用带头尾实体标记的 SciBERT 关系分类器判断 USED_FOR / EVALUATED_ON / NO_RELATION。参考标注采用 AI 辅助初标、用户逐条人工审核；V1 标签及 V2 Train65/Dev20 已经用户明确确认，在已裁决范围内作为人工复核金标准。确认来源为用户聊天，见 `human_review_confirmation.json`；不据此宣称第二人独立标注或盲测。未决标签不强行转为负例。

V1 正式 NER 为第 08 轮开发记录中选定的第 4 轮检查点，RE 为第 15 轮开发记录中选定的第 3 轮检查点。训练、验证与历史测试记录封存，交付期间不重新使用旧测试调参。实际权重路径、大小、SHA-256 和生产标志见 `models.json`。

V2 输入完整摘要。训练使用冻结 Train65 的 941 个实体和 674 个已裁决实体对；未决项排除。按证据组每轮取样，251 组中 USED_FOR 196、EVALUATED_ON 29、NO_RELATION 26。随机种子为 20261011，NER 与 RE 均训练 6 轮，各按固定开发集规则选第 5 轮。NER 102 步、RE 378 步。开发集 Dev20 已暴露，test20 正文封存。

4. 真实实验结果与评价边界

以下百分比来自封存实际结果，不是本次重新训练所得。交付核验不改变成绩。完整原始指标保存在 `experiment_comparison.json`。

结果	Precision	Recall	F1	评价范围
V1 题名 NER	73.44%	75.32%	74.37%	历史人工复核参考测试，144/200 篇
V1 题名端到端 RE	58.57%	61.65%	60.07%	历史人工复核参考测试，138/200 篇
V2 摘要 NER	58.41%	66.22%	62.07%	Dev20 人工复核参考，299 个实体

结果	Precision	Recall	F1	评价范围
V2 摘要端到端 RE 条件范围	12.46%	42.17%	19.24%	Dev20，361/974 对已裁决，37.06%

V1、V2 输入长度、标签定义及可评分范围不同，不能用上述分数直接计算模型退步或进步。V2 完整端到端 F1 为 null，不能将 19.24% 当成完整 F1 或正式测试成绩。F1 不等于 Accuracy，也不能通过 1−F1 推断候选边错误率。

V1 首页另外披露新增留出队列的端到端 F1 44.28%、覆盖 87.5%，该队列与历史测试不同；不得只选择较高分作为全部应用效果。历史 RE 模块参考实体输入 F1 99.25% 也不等于真实端到端可靠性。

V2 RE 类别（输入参考实体）	Precision	Recall	F1
USED_FOR	89.08%	100.00%	94.22%
EVALUATED_ON	77.61%	100.00%	87.39%
NO_RELATION	100.00%	2.08%	4.08%

正关系 micro F1 为 93.02%，类型多数基线为 92.88%，增益仅约 0.14 个百分点。48 个负例只正确拒绝 1 个，说明关系模块尚不能可靠辨别语义不成立的合法实体对。

5. 有边界对照实验，不上线

V1 题名扩充实验在同一固定验证范围中，NER F1 从 75.14% 到 78.36%，Pipeline F1 从 66.47% 到 70.10%，但稀有类别护栏未通过，因此未替换生产。这些是开发分数，不与旧测试直接比提升。

V2 合法 BIO 解码将非法转移从 177 降为 0，NER F1 从 62.07% 到 62.87%，TASK F1 从 43.48% 到 44.80%。合法序列不保证实体语义或边界正确。一次 RE 类别加权将 NO_RELATION 召回从 2.08% 到 4.17%，仍仅正确拒绝 2/48，未解决主要问题。

V2 预定 Pipeline 组合	条件 Precision	条件 Recall	条件 F1
argmax NER + 原 RE	12.46%	42.17%	19.24%
合法 BIO + 原 RE	11.61%	45.69%	18.51%

V2 预定 Pipeline 组合	条件 Precision	条件 Recall	条件 F1
argmax NER + 加权 RE	12.88%	41.53%	19.67%
合法 BIO + 加权 RE	11.97%	45.05%	18.91%

四组全部报告，均是同一已暴露开发集的部分参考条件结果，完整 F1 均未提供。不选择最高项冒充新正式测试。V2 保留为实验成果，冻结停止。

6. 应用实现与演示

正式入口 `http://127.0.0.1:8765/`，启动 `Start-Delivery.cmd`。用户先启动 Neo4j Desktop 实例，再输入数据库密码；密码不写入文件、报告或压缩包。应用使用本机只读 HTTP 接口，中文词表展开、论文详情、作者身份、候选证据、局部图、作者 2 跳、方法 4 跳及 JSON/TXT 候选清单导出。

五篇 V1 演示书目和实际详情保存在 `v1_demo_papers.json`；实际冻结权重重新加载后进行五篇题名推理，见 `v1_actual_inference.json`。这不是准确率评测，也不声称五篇都是正确抽取。

摘要演示入口 `/delivery-demo` 使用三篇已存在的训练侧摘要：Codex、SQuAD、SuperGLUE，展示用户逐条审核的人工参考高亮、原文证据、离线关系示意图及审核确认状态。没有新采集或新训练，也没有把 V2 摘要关系写入 V1。原文来源及限制保留，训练样例不可当作独立泛化证明。

用户已明确确认三篇演示论文均经阅读审核，未勾选属于操作遗漏；随后确认 V2 Train65/Dev20 及 V1 参考标签均经逐条审核。交付记录采用该直接确认，不伪造用户点击或独立评审。参考标签的人审状态不等于全库模型预测经人工核验。SQuAD 冻结标签的已知漏标作为缺陷展示，不在交付冻结后悄悄修改标签。

历史结果 JSON 中的 AI_reference / humanGold=false 字段保留原执行时记录，新增确认文件补充标签来源，不覆盖数据或更改分数；未决关系仍掩码，V2 仍仅有部分关系参考覆盖。实际浏览器截图、视频及交互收据保存于同目录；原录屏与部分截图早于本次来源更正，旧措辞以当前确认说明为准。录屏展示本机真实应用操作，不是模拟页面；无配音版按演示操作文稿说明。

7. 验收、依赖与提交边界

`Verify-Delivery.cmd` 校验提交文件 SHA-256、正式 graphId、真实检索、三种非空图及错误请求拒绝。验收收据区分实际推理、图谱数量检查、HTTP 功能及浏览器操作，不将工程检查数量当作语义正确率。

提交 ZIP 包含源码、已处理书目、正式图谱、模型配置与 tokenizer、V1 两个生产权重、V2 原始 NER/RE 和加权 RE 共五份实际权重、Train65/Dev20 冻结数据、指标、报告和演示证据。逐成员重新读取校验 SHA-256。原交付包已解压到独立目录，首次运行创建新虚拟环境并成功安装依赖；498 个文件哈希与九项 HTTP 检查通过，8767 解压版也完成实时检索/图谱核验，收据见 `relocated_runtime_check.json`。这不是空库导入或另一台机器验收。

不包含个人数据库、密码、虚拟环境、Neo4j 安装程序、完整 DBLP XML 及封存 test20 正文。新机器需 Python 3.12+、Neo4j（支持 HTTP Query v2），首次启动可安装已固定轻量依赖；模型推理另需 `requirements-training.txt` 的 Torch/Transformers。本机验证不等于离线裸机随包即用、所有 Neo4j 版本兼容或公网部署验收。

8. 已知限制与截止决策

P0：正式系统可启动、权重真实保存、图谱与文件一致、提交可验证；发现阻断即修复。P1：只修影响检索、展示、导出的缺陷。P2：长尾标签扩充、完整作者消歧、全量概念归一、摘要模型晋级、语义检索 Agent、全文证据和多用户部署均延后。

当前成果适合课程展示“采集清洗—深度学习抽取—Neo4j 入库—图谱检索应用”的闭环，不是高可靠科研事实库。精度及召回仍存在不足，无法保证教师评分。课程价值在于真实实现、可复现证据、正确评价及明确失败分析，而不是隐去低分或包装虚假的完整 F1。

附：本次真实浏览器截图

V1 中文检索（历史截图，标签来源以当前确认记录为准）



V1 实体及候选关系证据



V1 真实 Neo4j 局部图

导出书目与证据JSON　导出参考文献草稿TXT

节点图与多跳探索

论文局部图　共享作者 · 2跳　同方法文献 · 4跳　放大 / 适应窗口

15节点 / 18关系 · 13条路径 · 真实Neo4j

最多30条路径，不是整库全图。选中节点可查看原始属性；论文节点可打开文献证据。同方法仅按模型概念匹配，不是引用关系。

论文/文献（Publication） 作者（Person） 会议/期刊（Venue） 概念（Concept） 实体提及（Mention） 候选断言（Assertion）



▶ 查看实际连接路径与完整名称

V2 冻结人工复核参考高亮及关系证据

SQuAD: 100,000+ Questions for Machine Comprehension of Text

来源：http://arxiv.org/abs/1606.05250v3 · train 演示样例，非独立测试

We present the Stanford Question Answering Dataset (SQuAD), a new reading comprehension dataset consisting of 100,000+ questions posed by crowdworkers on a set of Wikipedia articles, where the answer to each question is a segment of text from the corresponding reading passage. We analyze the dataset to understand the types of reasoning required to answer the questions, leaning heavily on dependency and constituency trees. We build a strong logistic regression model, which achieves an F1 score of 51.0%, a significant improvement over a simple baseline (20%). However, human performance (86.8%) is much higher, indicating that the dataset presents a good challenge problem for future research. The dataset is freely available at https://stanford-qa.com

原文核对说明：SQuAD 名称及缩写、reading comprehension、logistic regression 的跨度可核对。模型 F1=51.0% 是论文作者报告的结果，不是本项目抽取成绩。冻结标签可能漏掉 answer the questions，候选修订未用于训练，交付不改标签。

▼ 已裁决关系与原文证据（用户逐条审核的人工参考）

logistic regression → EVALUATED_ON → Stanford Question Answering Dataset
The sole dataset being presented/analyzed is Stanford Question Answering Dataset (SQuAD); which directly attaches the reported score to logistic regression.


```
{
  "end": 563,
  "start": 15,
  "text": "Stanford Question Answering Dataset (SQuAD), a new reading comprehension dataset consisting of 100,000+ questions posed by crowdworkers on a set of Wikipedia articles, where the answer to each question is a segment of text from the corresponding reading passage. We analyze the dataset to understand the types of reasoning required to answer the questions, leaning heavily on dependency and constituency trees. We build a strong logistic regression model, which achieves an F1 score of 51.0%, a significant improvement over a simple baseline (20%)."
}
```


logistic regression → EVALUATED_ON → SQuAD
The sole dataset being presented/analyzed is Stanford Question Answering Dataset (SQuAD); which directly attaches the reported score to logistic regression.


```
{
  "end": 563,
  "start": 52
```